

# Отчёт: умный поиск по каталогу

## 1. Результаты

Три конфигурации одного пайплайна (см. docs/ARCHITECTURE.md ), измерены evaluate.py на всех 30 запросах queries.csv , каталог обогащён ( data/enrichment.csv , 21/211 товаров — см. п.3 ниже).

**Модели и библиотеки** (self-hosted, без GPU и API-ключей): rank\_bm25 — самодостаточный BM25 без внешней СУБД, соответствует масштабу теста; pymorphy3 — единственный поддерживаемый морфоанализатор для русского с FSM-предсказанием лемм для незнакомых слов ( pymorphy2 не совместим с Python 3.11+); rapidfuzz — C++-реализация Левенштейна, быстрее чистого Python; multilingual-e5-base через text-embeddings-inference — self-hosted эмбединги (приватность каталога; сравнение с bge-m3 — см. Журнал решений); FastAPI — минимальный оверхед и готовая Pydantic-валидация для одного эндпоинта.

| Подход                                         | Precision@1  | Hit@3        |
|------------------------------------------------|--------------|--------------|
| Fuzzy → Lexical (бейзлайн)                     | 66.7%        | 90.0%        |
| Semantic (чистый вектор, диагностика)          | 80.0%        | 86.7%        |
| <b>Hybrid = RRF(Fuzzy → Lexical, Semantic)</b> | <b>76.7%</b> | <b>93.3%</b> |

**В работу ставим Hybrid** (это и реализовано в /search ). У чистого вектора Precision@1 выше (80.0% против 76.7%), но Hit@3 ниже (86.7% против 93.3%) — и именно Hit@3 важнее для продукта, так как некоторые query отвечают больше чем 1 товару.

Кроме того, чистый вектор — более хрупкий режим: его высокий Precision@1 частично держится на том, что e5-модель не игнорирует буквальное совпадение слов, а на точных SKU/названиях (не в этих 30 запросах, но в реальном каталоге) dense retrieval по литературе деградирует чаще, чем лексика. Гибрид даёт устойчивость по обоим типам запросов за счёт двух независимых сигналов.

Без обогащения каталога гибрид даёт 73.3%/86.7% — обогащение ( data/enrichment.csv ) даёт **+3.4 п.п. Precision@1 / +6.6 п.п. Hit@3** ценой ручной разметки 21 товара.

**Два числа с учётом спорного эталона** (см. «Замечания к эталону»; метрики по всем 30 — основные, приведённые в таблице выше):

|                      | n  | Precision@1 | Hit@3 |
|----------------------|----|-------------|-------|
| Все 30 запросов      | 30 | 76.7%       | 93.3% |
| Без 1 спорного (#20) | 29 | 79.3%       | 96.6% |

Только #20 исключён как вероятно некорректный эталон — не сам ответ товара, а разметка.

## 2. Разбор ошибок (Hybrid, лучший подход)

7 промахов Hit@1 из 30 (2 из них — также промахи Hit@3), сгруппированы:

**Спорный/неоднозначный эталон (1, #20)** «чем надуть шарики без гелия» → эталон ШВ-9209 «Набор шаров», хотя запрос явно про устройство для надувания; наша система на первом месте находит именно насос (РУН-13119) — вероятно, правильный ответ отличается от эталона.

**RRF tie-break на равном score (2, #15, #19)**

- #15 «гирлянда занавес 3 на 2» — эталон и конкурент получают идентичный итоговый score (0.45); хотя эталон («Гирлянда-

занавес 3х2 м») точнее по смыслу, решает tie-break по артикулу.

- #19 «куда положить деньги маме на день рождения» — тот же механизм: эталон («Любимой маме») и конкурент («С Днем Рождения», тоже валидный конверт для денег) получают равный score (0.45/0.45), решает tie-break. В отличие от #20 эталон здесь не под вопросом — оба кандидата в каталоге уместны, просто RRF не развёл их по score.

#### Ложное совпадение с конкурентом по отдельному слову (2, #18, #26)

- #18 «зелёная бумажная стружка, чтобы заполнить коробку» — и лексика, и вектор цепляются за слова «зелёный»/«коробка» в названии совсем другого товара («Набор коробок... Зеленые листья»), хотя нужен наполнитель.
- #26 «во что упаковать бутылку вина в подарок, крафт» — конкурент («Набор коробок... Крафт без рисунка») обгоняет эталон на минимальном разрыве (0.32 vs 0.29) только за счёт слова «крафт»; усугубляется тем, что лемма «подарок» (запрос, существительное) ≠ «подарочный» (товар, прилагательное).

#### В названии товара нет отличительного слова из запроса (2, #23, #30)

- #23 «гирлянда на ёлку» — несколько похожих гирлянд в каталоге, ни у одной в названии нет слова «ёлка»/«ёлочная» — эталон текстуально неотличим от конкурентов, итоговый ранг 18 (вне топ-10).
- #30 «...метра два» — эталон (гирлянда 2 м) проигрывает по score гирляндам 5 м: числовая характеристика длины не даёт отдельного веса ни в лексике, ни в векторе.

### 3. Замечания к данным и эталону

---

- #20 «чем надуть шарики без гелия» — см. выше, вероятно некорректный эталон: в каталоге есть насосы, которые семантически точнее отвечают на вопрос «чем», чем набор шаров.
- Возможный **дубликат позиций в каталоге**: ТМ-3862 и ТМ-2999 — похожие названия («салфетки с единорогом»), риск систематически путать эталон.
- **Сокращения в наименовании** («мат.лам.», «тисн.», «подар.») ломают токенизацию без ручной расшифровки — расширяемый словарь покрывает только найденные на этих 211 позициях случаи, не гарантирует полноту на ~8000.
- **Единицы измерения** («см», «мм») паразитно лемматизируются в случайные слова (например «см» → «смотреть», затрагивало ≈48% каталога) — исправлено фильтром стоп-токенов.
- **Числовые атрибуты** (длина, диаметр) не выделяются как структурированный признак — запросы вида «метра два» полагаются только на текстовое совпадение (см. #30).

### 4. Журнал решений

---

| Что предложил ИИ-ассистент                                                                       | Что взяли                                                                                                                               | Что отвергли и почему                                                                                                                                                |
|--------------------------------------------------------------------------------------------------|-----------------------------------------------------------------------------------------------------------------------------------------|----------------------------------------------------------------------------------------------------------------------------------------------------------------------|
| 5 вариантов поиска (лексика, fuzzy отдельно, вектор, LLM-перанкинг, гибрид); рекомендовал гибрид | Гибрид как основа; сравнение — Fuzzy → Lexical vs Hybrid как абляция одного пайплайна, не два решения; vector_only — только диагностика | LLM-перанкинг основным механизмом — дорого на весь каталог; чистые лексика/fuzzy по отдельности — не покрывают перефразировки/опечатки                               |
| Сравнить self-hosted vs API-эмбединги                                                            | Self-hosted ( multilingual-e5-base через TEI)                                                                                           | API — приватность каталожных данных важнее скорости/качества из коробки                                                                                              |
| In-memory Python (дешёвая миграция позже) — в ответ на вопрос пользователя про Postgres          | In-memory Python                                                                                                                        | Postgres с самого начала — пользователь сам к нему склонялся; отклонил: оверхед не окупается на масштабе теста (211-8000 позиций, 1 инстанс), нужда в будущем неясна |
| Fuzzy как третья параллельная ветка в RRF                                                        | Fuzzy как шаг коррекции токенов перед BM25 (интуиция пользователя, ИИ обосновал)                                                        | Третья ветка — роль fuzzy это починка токена, не самостоятельный сигнал релевантности                                                                                |
| Tie-break по числу веток, подтвердивших товар                                                    | Tie-break по лучшему рангу хотя бы в одной ветке; затем — по артикулу                                                                   | По числу веток — топит paraphrase-случаи (товар, найденный только вектором на ранге 1, проигрывал бы слабо подтверждённому обеими ветками)                           |
| Обогатить search_text шаблоном на всю категорию                                                  | Точечные keyword-правила только там, где функция товара не самоочевидна (21/211)                                                        | Категориальный шаблон — не добавляет факта, создал регресс (#26: ранг 2 → 7)                                                                                         |
| Проверить BAAI/bge-m3 как альтернативу                                                           | multilingual-e5-base                                                                                                                    | bge-m3 — oomkilled при прогреве (15 ГБ RAM, вдвое тяжелее)                                                                                                           |
| Тест Макнемара для статзначимости Fuzzy → Lexical vs Hybrid                                      | Не делать                                                                                                                               | Надстройка сверх требований задания на этом этапе                                                                                                                    |

5. Границы

Не сделано / сознательно отложено:

- Однокоренные слова («шарик»≠«шар», «подарок»≠«подарочный») не решены на уровне лексики — держится только на векторной ветке; нужен синонимический слой над леммами или более разговорные формулировки в обогащении.
- Обогащение — 21/211 товаров, правила пишутся вручную; на полном каталоге (~8000) нужно либо расширять их вручную, либо отдельный generative-сервис с контролем качества.
- Поле категория не индексируется — не понадобилось на этих 30 запросах, к тому же есть ощущение, что оно скорее добавит шума (общий текст категории размывает эмбединг и лексику конкретного товара), чем пользы.
- Результаты на 30 запросах по базе из 211 товаров не гарантируют подобный исход на базе из 8000.
- Нет unit-тестов — только сквозная проверка через evaluate.py и ручные запросы к живому API.
- Риски in-memory на масштабе продакшена (переиндексация при обновлении из 1С, персистентность эмбедингов, синхронизация реплик) — задокументированы в docs/ARCHITECTURE.md п.7, не реализованы: вне объёма задания.
- Будь больше времени — почитал бы больше про LLM-перанкинг, возможно применил бы его.

6. Время

Оценка до начала: **7-8 часов** (6ч — базовая оценка задания, взял запас на методы поиска). Фактически — **9 часов**, перерасход из-за: (1) бага OOV-проверки — сверка шла до лемматизации, а не после, тот же класс проблемы всплыл в

сокращениях каталога («мат.лам.»); (2) обогащения каталога сценариями — не было в исходном плане, решили по итогам обсуждения архитектуры, с экспериментом «категориальный шаблон vs keyword-правила» и откатом первого варианта.